



Universidad San Carlos de Guatemala
Ingeniería en Ciencias y Sistemas
Sistemas Organizacionales y Gerenciales 2

INFORME FINAL DE ANALISTA DE DATOS JUNIOR

Carlos Samuel Aguilar Acosta - 202200131
Gabriel Emilio Herrera Balán - 202201133
Bismarck Estuardo Romero Lemus - 201708880
Pedro Alejandro Zetino Páez - 202004750
Christian Alexandro Aragón García - 202000308



PRESENTACIÓN DEL INFORME

El presente documento constituye el informe final del Grupo 4 para la Práctica 1 del curso Sistemas Organizacionales y Gerenciales 2, elaborado desde el rol de analista de datos junior de una empresa de comercio electrónico que se encuentra en proceso de expansión hacia una sucursal física y que ha decidido incorporar un agente de inteligencia artificial conversacional capaz de entregar análisis de ventas bajo demanda. El objetivo del trabajo fue transformar 6,500 registros transaccionales del año 2021 en información accionable para la gerencia, apoyándose en una base de datos relacional en la nube, en técnicas de análisis estadístico con Python, y en un agente conversacional construido con Google ADK que consulta dichos análisis a través de un servidor MCP (Model Context Protocol) desarrollado por el equipo.

2. PLANIFICACIÓN DEL PROYECTO

2.1 División de tareas entre los miembros del equipo

El grupo estuvo conformado por cinco integrantes y, desde el inicio, dividimos el trabajo según lo que necesitaba el proyecto: base de datos, análisis, visualizaciones, el agente de IA y la redacción del informe. La distribución quedó así:

- **Bismarck Estuardo Romero Lemus (201708880)**: se encargó de la base de datos y de dejarla lista en la nube, para que el resto del equipo pudiera consultarla en cualquier momento.
- **Pedro Alejandro Zetino Páez (202004750)**: generó las gráficas del análisis y explicó qué mostraba cada una, tanto en la parte de tendencias como en la de segmentación.
- **Gabriel Emilio Herrera Balán (202201133)**: construyó el servidor MCP y el agente conversacional, incluyendo la interfaz con la que se interactúa con él.
- **Carlos Samuel Aguilar Acosta (202200131)**: redactó y armó este informe, uniendo el trabajo de todo el equipo en un solo documento.
- **Christian Alexandro Aragón García (202000308)**: hizo el análisis exploratorio de datos (EDA) y de tendencias, es decir, encontró los patrones sobre meses fuertes, promociones y comportamiento general de las ventas que luego se convirtieron en gráficas y conclusiones.

El trabajo se organizó de forma colaborativa a través de un repositorio compartido en GitHub, donde cada integrante subía su parte y el equipo revisaba los avances en conjunto.

2.2 Herramientas y tecnologías utilizadas, y justificación de su elección

Para este proyecto elegimos herramientas pensando en que fueran fáciles de conectar entre sí y en que el equipo ya tuviera algo de experiencia con ellas:

- **Base de datos en la nube (PostgreSQL en AWS RDS)**: la elegimos porque entra dentro de la capa gratuita de AWS, es sencilla de configurar y permite que los cinco nos conectemos a la misma base sin tener que andar compartiendo archivos.



- **Python, con librerías como pandas y matplotlib/seaborn:** lo usamos para limpiar los datos, hacer los cálculos y crear las gráficas, porque es el lenguaje con el que el equipo se siente más cómodo para este tipo de trabajo.
- **Google ADK y FastMCP para el agente conversacional:** Google ADK facilita construir un agente que entienda lenguaje natural, y FastMCP permite conectarlo con los análisis que ya teníamos hechos, sin tener que duplicar código.
- **GitHub como repositorio central:** nos permitió trabajar en paralelo los cinco y llevar un historial de los cambios que cada quien iba haciendo.

2.3 Establecimiento de plazos por fase del proyecto

Aunque el trabajo se organizó con cierta flexibilidad según la disponibilidad de cada integrante, en términos generales el proyecto se completó en una semana, siguiendo este cronograma:

Día	Actividad principal	Responsable(s)
Día 1	Preparación de los datos y carga a la base de datos en la nube	Bismarck
Día 2	Análisis exploratorio y de tendencias	Christian, con apoyo de Pedro en las gráficas
Día 3	Segmentación y correlación de clientes	Pedro, con apoyo de Christian en el análisis
Día 4	Desarrollo del servidor MCP y del agente conversacional	Gabriel
Día 5	Pruebas del agente y ajustes finales	Gabriel, con apoyo de todo el equipo
Día 6	Redacción del informe y recopilación de resultados	Carlos
Día 7	Revisión final y entrega	Todo el equipo

Cronograma de una semana seguido por el equipo.

3. PROCESO DE ANÁLISIS

3.1 Preparación de datos (Punto 1 del alcance)

Antes de poder analizar nada, había que dejar los datos en condiciones. Este trabajo se hizo en **src/etl.py**, sobre los 6,500 registros del archivo **Venta_online_c.csv**. En resumen, seguimos estos pasos:

- **Leer el archivo:** el CSV no siempre trae los nombres de columna escritos igual (por ejemplo, a veces dice 'Género' y otras 'id_genero'), así que primero normalizamos esos nombres para que el resto del proceso no dependiera de cómo vino escrito cada uno.



- **Quitar duplicados:** buscamos filas que estuvieran repetidas exactamente y las eliminamos, dejando registro de cuántas se quitaron para poder explicarlo si alguien pregunta.
- **Revisar datos faltantes o raros:** las ventas sin un cliente asociado no sirven de nada, así que esas se descartaron. Y cuando un campo tenía un valor fuera de lo posible (un género distinto de 0 o 1, un navegador que no existe), preferimos dejarlo vacío antes que inventarle un valor.
- **Corregir los tipos de dato:** los montos venían a veces con símbolo de moneda o comas de miles, así que se limpiaron antes de convertirlos a número. Las fechas se ajustaron a un formato único, y los campos que son categorías (género, método de pago, navegador, boletín, vale) se validaron contra los valores que realmente deberían tener.
- **Separar la información en dos tablas:** por un lado quedaron los datos del cliente (edad, género, total gastado, número de compras) y por otro cada venta individual, para no repetir la información del cliente en cada transacción.
- **Subirlo a la nube:** con el esquema ya definido en `sql/schema.sql`, cargamos todo a una base de datos PostgreSQL en AWS RDS usando SQLAlchemy.

3.2 Decisiones tomadas durante el análisis exploratorio de datos (Punto 2)


Una de las primeras cosas que notamos es que el gasto de los clientes no se comporta de forma pareja: hay un grupo pequeño que gasta mucho más que el resto, y eso hace que el promedio por sí solo pueda ser engañoso. Por eso, además del promedio, calculamos la mediana y otras medidas para cada variable numérica, en lugar de quedarnos solo con un número. Por ejemplo, mientras que el promedio de venta total por cliente es de \$206.24, la mitad de los clientes gasta \$137.35 o menos: si solo miráramos el promedio, habríamos pensado que el cliente típico gasta bastante más de lo que realmente gasta. También decidimos separar claramente la tienda física del resto de los navegadores, porque en los datos originales la tienda física comparte columna con los navegadores web (aparece como el valor 0), y si no se separa, terminaba pareciendo el 'navegador' más usado, cuando en realidad es un canal completamente distinto.

Así se ven las estadísticas principales de las variables numéricas:

Variable	Media	Mediana	Moda	Desv. Std	Min	Max	IQR
Venta_total (cliente)	206.24	137.35	98.00	215.55	9.00	3169.00	197.50
MontoCompra (transacción)	39.79	35.76	37.15	19.52	7.24	199.35	22.34
N_Compras (cliente)	5.09	4.00	2.00	3.96	1.00	25.00	5.00
Edad (cliente)	36.31	36.00	18.00	11.36	18.00	79.00	16.00
Tiempo de sesión (s)	767.38	768.00	852.00	181.75	180.00	1443.00	241.00








Distribucion de Variables Numericas Principales (Análisis EDA)



Gráfica 1. Distribución de las variables numéricas principales.




Cómo se reparten las ventas según método de pago, canal, boletín y vale: la mayoría paga con tarjeta de crédito (59% de las compras, unos \$152,600 en total), después viene tarjeta de débito (22%) y por último efectivo (19%). La tienda física sigue siendo el canal más fuerte, con poco más de la mitad de las ventas; dentro de las compras por internet, un navegador en particular (Navegador 1) se lleva casi la mitad del tráfico. Algo interesante: los clientes suscritos al boletín gastan un poco más por compra (cerca de un 5% más), y quienes usan un vale de descuento gastan bastante más, casi un 17% por encima de quien no lo usa.





3.3 Análisis de tendencias (Punto 3)

- **Mes con más ventas:** marzo de 2021, muy cerca seguido de diciembre. Los dos meses rondan los \$23,000 en ventas.
- **Mes con menos ventas:** noviembre, seguido de septiembre; ambos se quedan alrededor de \$20,000.
- **El navegador favorito:** el Navegador 1 es, por mucho, el más usado dentro de las compras digitales (4 de cada 10 compras en línea pasan por ahí); el menos usado es el Navegador 4.
- **Pagos en efectivo o contra entrega:** representan cerca de una de cada cinco ventas, y un 18% de todo lo facturado en el año.
- **Meses donde más se usaron boletín y vale:** diciembre fue el mes con más gente suscrita al boletín, y marzo el de más vales usados. No es casualidad que sean justo los dos meses de mejores ventas: las promociones parecen empujar directamente las compras.



3.4 Segmentación de clientes (Punto 4)

Dividimos a los clientes en cuatro grupos de edad (18-25, 26-40, 41-55 y 56 en adelante). El grupo de 26 a 40 años es el más grande y el que más factura: junta poco más de la mitad de los clientes y poco más de la mitad de las ventas. Aún así, no gastan más por compra que el resto de las edades; simplemente son más. Comparando hombres y mujeres, no encontramos diferencias reales en cuánto compran ni en cómo pagan: ambos grupos se comportan de forma muy parecida. Donde sí aparece una diferencia clara es al mirar boletín y vale juntos: los clientes que usan ambas cosas tienen el ticket promedio más alto de todos, casi 20% por encima de quien no usa ninguna.

Gráfico 1: Facturación Total y Ticket Promedio por Rango de Edad




Gráfico 2: Comportamiento Comercial Comparativo según Género (0 vs 1)







Gráfico 3: Desempeño Comercial según Segmento de Fidelización (Boletines y Vales)



3.5 Análisis de correlación (Punto 5)

La edad prácticamente no tiene relación con cuánto gasta un cliente: no importa si tiene 20 o 60 años, el gasto no cambia de forma real por eso. El género tampoco se relaciona con el método de pago que la gente elige. En cambio, sí encontramos una conexión clara entre estar suscrito al boletín y usar vales: un cliente suscrito al boletín tiene casi tres veces más probabilidad de usar un vale que uno que no lo está. Y si miramos todas las variables juntas, lo que más se relaciona con el total gastado por un cliente es, sin sorpresa, cuántas veces ha comprado antes.

Gráfico 4: Análisis de Correlación y Dispersión: Edad vs Venta Total Acumulada






Gráfico 5: Distribución de Métodos de Pago según Género (Heatmap de Contingencia)
[Chi² = 3.73, p-val = 0.1546, V de Cramér = 0.0240]




Gráfico 6: Matriz de Correlación Multivariable de Variables Transaccionales y Demográficas







Gráfico 7: Distribución y Dispersión del Monto de Compra por Cuadrante Promocional (Boxplot)



3.6 Desafíos encontrados y cómo se superaron

- **Calcular la mediana y la moda dentro de la base de datos:** PostgreSQL no las calcula tan directo como un promedio. Usamos un par de funciones estadísticas propias de PostgreSQL para poder pedir las directamente por consulta, sin tener que traer todos los datos a Python primero.
- **La tienda física escondida como si fuera un navegador:** al principio, agrupar por 'navegador' hacía parecer que la tienda física era el navegador más usado, lo cual no tenía sentido. Tuvimos que separar el canal físico de los navegadores web para que el análisis fuera correcto.
- **Montos con mucha variación entre clientes:** como hay clientes que gastan muchísimo más que el promedio, tuvimos que acompañar siempre el promedio con la mediana para no dar una idea equivocada del cliente típico.
- **Que el agente de IA entendiera bien qué le estaban preguntando:** al principio confundía preguntas parecidas y no sabía cuál herramienta usar. Reescribimos las descripciones de cada herramienta usando el mismo lenguaje que usaría un gerente al preguntar, y eso resolvió el problema.

3.7 Integración con el Agente Conversacional de IA (Google ADK + MCP)

Construimos un servidor (`mcp_server/server.py`) que toma cada análisis que hicimos y lo deja disponible como una herramienta que el agente de inteligencia artificial puede usar. El agente en sí (`agente/agent.py`) está hecho con Google ADK y responde en español a preguntas sobre las ventas de 2021, siempre consultando la base de datos real en lugar de inventar una respuesta. Lo probamos con varias preguntas típicas, como cuál fue el mes con más ventas o cuánto es la mediana del monto de compra, y en todos los casos el agente buscó el dato correcto en la base de datos antes de responder, tal como pedía el enunciado.



4. METODOLOGÍA DE SELECCIÓN DE VISUALIZACIONES (Punto 6)

No elegimos los gráficos al azar: para cada uno pensamos qué tipo de dato estábamos mostrando y qué pregunta queríamos que respondiera de un vistazo. En total armamos 14 gráficos (el enunciado pedía al menos 7), divididas entre la parte de exploración y tendencias y la parte de segmentación y correlación. La siguiente tabla resume el criterio detrás de cada tipo de gráfico:

Gráfico	Tipo	Se usa para	Por qué lo elegimos
Histogramas	Barras / densidad	Ver cómo se distribuye un valor	Muestra si los datos están parejos o si hay valores raros, algo que un promedio solo no cuenta.
Barras por método de pago / navegador / boletín-vale	Barras	Comparar categorías	Es la forma más clara de comparar cantidades entre grupos distintos.
Serie de tiempo mensual	Línea	Ver la evolución en el año	Deja ver de inmediato los meses altos y bajos, y si hay un patrón que se repite.
Barras con edad	Barras + línea	Comparar volumen e intensidad a la vez	Permite ver cuánto factura cada grupo y cuánto gasta en promedio, sin mezclar las dos escalas.
Dispersión con línea de tendencia	Scatter	Ver si dos variables están relacionadas	Es la forma más directa de mostrar si una variable sube o baja según la otra.
Mapa de calor de cruce	Heatmap	Cruzar dos categorías	Facilita ver de un vistazo dónde se concentran los casos al cruzar dos variables.
Mapa de calor de correlación	Heatmap	Ver muchas relaciones a la vez	Resume en una sola imagen cómo se relacionan todas las variables entre sí.
Diagrama de caja por grupo	Boxplot	Comparar la dispersión entre grupos	Muestra no solo el promedio sino qué tan parejos o dispersos son los datos de cada grupo.

5. CONCLUSIONES Y RECOMENDACIONES ESTRATÉGICAS (Punto 7)

5.1 Conclusiones clave

1. Las ventas suben cuando hay promociones activas, no por casualidad.

Marzo y diciembre fueron los meses más fuertes del año, y también los meses donde más gente usó vales de descuento y se suscribió al boletín. No creemos que sea coincidencia: cuando la empresa lanza estas promociones, las ventas responden. Eso quiere decir que septiembre y noviembre no son meses flojos por falta de demanda, sino porque ahí hubo menos actividad de marketing. Tiene sentido entonces mover parte del esfuerzo promocional hacia esos meses bajos, en lugar de reforzar todavía más los meses que ya van bien por su cuenta.



2. Hombres, mujeres y distintas edades compran de forma muy parecida.

No encontramos diferencias reales en cuánto gasta o cómo paga un cliente según su género o su edad: todos se comportan de manera bastante similar. Lo que sí cambia es el tamaño de cada grupo: los clientes de 26 a 40 años son, con diferencia, el grupo más grande y el que más aporta a las ventas totales, simplemente porque son más personas, no porque gasten más cada uno. Esto simplifica bastante la estrategia: no hace falta una campaña distinta para cada género o edad, pero sí conviene cuidar especialmente a ese grupo de 26 a 40 años, porque perderlos pesaría más que perder a cualquier otro grupo.

3. El boletín y el vale funcionan mejor juntos que por separado.

Los clientes que usan boletín y vale a la vez tienen el ticket de compra más alto de todos, casi un 20% arriba del cliente que no usa ninguno de los dos. El vale parece ser el que realmente empuja el gasto, mientras que el boletín funciona como la puerta de entrada: quien está suscrito tiene muchas más probabilidades de terminar usando un vale. Para la empresa, esto es una señal clara de que vale la pena invertir en sumar gente al boletín, porque cada nuevo suscriptor tiene más chances de convertirse en una venta más grande.

4. Lo que mejor predice cuánto vale un cliente es cuántas veces ha comprado antes.

De todas las variables que teníamos, ninguna se relaciona tanto con el total gastado por un cliente como su historial de compras: entre más veces ha comprado, más ha gastado en total, lo cual suena obvio pero es más fuerte que cualquier otra relación que encontramos. La edad y el género, en cambio, casi no dicen nada sobre cuánto va a gastar alguien. Esto sugiere que, si la empresa quiere identificar a sus clientes más valiosos, debería fijarse primero en la frecuencia de compra y en el uso de boletín y vale, más que en datos demográficos.

5.2 Acciones concretas propuestas por estudiante

Como pide el enunciado, cada analista propone dos acciones concretas a partir de lo que encontró:

- **Christian Aragón (EDA y Tendencias) - Acción 1:** Lanzar los cupones y correos del boletín unas semanas antes de septiembre y noviembre, repitiendo lo que funcionó en marzo y diciembre, para reforzar esos meses más flojos.
- **Christian Aragón (EDA y Tendencias) - Acción 2:** Cuidar primero la velocidad y la experiencia de pago del Navegador 1, ya que es por donde pasa casi la mitad del tráfico digital.
- **Pedro Zetino (Segmentación y Correlación) - Acción 1:** Dar un vale de bienvenida a quien se suscribe al boletín, apuntando sobre todo al grupo de 26 a 40 años, que ya es el que más compra.
- **Pedro Zetino (Segmentación y Correlación) - Acción 2:** Negociar con los bancos cuotas sin intereses en tarjeta de crédito, ya que es el método de pago preferido por casi 6 de cada 10 clientes, sin importar el género.
- **Carlos Aguilar - Acción 1:** Usar el agente de IA para armar automáticamente un resumen mensual de ventas que la gerencia pueda revisar sin tener que pedirlo, para que el equipo no pierda tiempo generando ese reporte a mano cada mes.



- **Carlos Aguilar - Acción 2:** Antes de abrir la tienda física, aplicar ahí las mismas promociones de boletín y vale que ya funcionan bien en el canal digital, en lugar de empezar de cero con la fidelización de clientes.
- **Gabriel Herrera (MCP Server y Agente) - Acción 1:** Llevar un registro de las preguntas que la gente le hace al agente, para ver qué tipo de análisis piden más seguido y usar eso como guía de qué nuevas herramientas conviene agregar al MCP Server primero.
- **Gabriel Herrera (MCP Server y Agente) - Acción 2:** Conectar el agente a una herramienta que el equipo ya use a diario, como Slack o Teams, para que cualquiera pueda preguntarle desde ahí en vez de tener que abrir una consola aparte.
- **Bismarck Romero - Acción 1:** Crear índices sobre las columnas más consultadas de las vistas para garantizar respuestas rápidas cuando se incremente el volumen de transacciones con la nueva tienda.
- **Bismarck Romero - Acción 2:** Configurar la carga automática de las ventas diarias y activar copias de seguridad continuas en AWS RDS para proteger la información de la nueva tienda física.

5.3 Respuestas a las preguntas planteadas (Punto 8)

a. ¿Cómo podrían estos hallazgos ayudar a diferenciarse de la competencia?

La combinación de boletín y vale es algo que pocas empresas del sector miden con tanto detalle, así que la compañía puede usar esa ventaja para armar campañas de fidelización más inteligentes que las de la competencia. Además, como el comportamiento de compra es muy parecido entre géneros y edades, el mensaje de marketing se puede simplificar y enfocar el presupuesto en mejorar la experiencia digital y la apertura de la tienda física. Y contar con un agente de IA que responde preguntas de negocio al instante ya es, de por sí, algo que la mayoría de competidores todavía no tiene.

b. ¿Qué decisiones se podrían tomar con este análisis para vender más y mejorar la satisfacción del cliente?

En lo inmediato, mover las campañas de vales y boletín hacia septiembre y noviembre, que son los meses más flojos, y lanzar una promoción de bienvenida para sumar gente al boletín, sobre todo en el grupo de 26 a 40 años. A mediano plazo, aplicar las mismas estrategias de fidelización en la tienda física, ya que hoy no las tiene y concentra más de la mitad de las ventas. También vale la pena cuidar el rendimiento del Navegador 1, por donde pasa la mayor parte del tráfico digital, y dejar que más áreas de la empresa (no solo los analistas) usen el agente de IA para resolver dudas del día a día.

c. ¿Cómo podría este análisis ayudar a ahorrar costos o mejorar la eficiencia?

El agente de IA evita que alguien tenga que armar a mano reportes que se repiten cada mes (ventas, navegador más usado, efecto de una promoción), lo cual libera tiempo del equipo para cosas más importantes. También ayuda saber que la edad y el género no explican el comportamiento de compra: la empresa puede dejar de invertir en campañas súper



segmentadas por esos datos y enfocar el presupuesto en lo que sí funciona, como el historial de compras y el uso de boletín y vale. Y como la base de datos ya está lista en la nube, sacar cualquier métrica toma segundos en lugar de horas.

d. ¿Qué datos adicionales recomendarían para obtener información aún más valiosa?

Sería útil conocer el costo de cada producto vendido, para poder calcular ganancia real y no solo el monto de las ventas. También ayudaría saber qué categoría de producto compra cada cliente, para ver si las promociones funcionan igual en todas o si conviene ajustarlas por tipo de producto. Una vez abierta la tienda física, conviene registrar de qué sucursal viene cada venta, para poder comparar entre ellas. Y del lado digital, sería valioso guardar datos de los carritos que se abandonan sin completar la compra, además de alguna medida de satisfacción del cliente después de comprar.

e. ¿Implementar un chat de IA que entregue este análisis afectaría a la empresa a futuro?

Sí, y de forma positiva. El agente que construimos ya demostró que puede responder preguntas de negocio sin que nadie tenga que saber SQL ni Python, lo cual acerca el análisis de datos a cualquier persona del equipo, no solo a quien programa. Siempre consulta la base de datos real antes de responder, así que no corre el riesgo de inventar cifras. Y como está armado de forma modular, agregar nuevos análisis en el futuro (por ejemplo, con los datos adicionales de la pregunta anterior) no debería requerir rehacer todo el sistema, solo sumar una pieza más.

6. DIAGRAMA DE LA BASE DE DATOS

El modelo relacional implementado en PostgreSQL (AWS RDS) sigue un esquema de tipo estrella: una tabla de hechos ventas (una fila por transacción) conectada a la dimensión clientes y a tres tablas de catalogo (cat_genero, cat_metodo_pago, cat_navegador) que traducen los códigos numéricos del CSV original a descripciones legibles, evitando redundancia y facilitando el mantenimiento de los catalogos.




Diagrama entidad-relación del modelo implementado en AWS RDS PostgreSQL.

7. CÓDIGO UTILIZADO PARA SU IMPLEMENTACIÓN

Se incluyen a continuación los fragmentos de código más representativos de cada capa de la solución. El código fuente completo del proyecto (ETL, análisis estadístico, MCP Server y agente conversacional) está disponible en el repositorio de GitHub del equipo, dentro de la carpeta Practica1/.

7.1 Esquema relacional (sql/schema.sql)

```
CREATE TABLE clientes (
  id_cliente  INTEGER PRIMARY KEY,
  edad        INTEGER,
  id_genero   SMALLINT,
  venta_total NUMERIC(12, 2),
  n_compras   INTEGER,
  CONSTRAINT fk_cliente_genero FOREIGN KEY (id_genero)
    REFERENCES cat_genero(id_genero) ON DELETE SET NULL
);

CREATE TABLE ventas (
  id_registro  SERIAL PRIMARY KEY,
  id_cliente   INTEGER NOT NULL,
  fecha_compra DATE NOT NULL,
  monto_compra NUMERIC(12, 3),
  id_metodo_pago SMALLINT,
  id_navegador SMALLINT,
  tiempo       NUMERIC(10, 2),
  boletin      SMALLINT CHECK (boletin IN (0, 1)),
  vale         SMALLINT CHECK (vale IN (0, 1)),
  CONSTRAINT fk_ventas_cliente FOREIGN KEY (id_cliente)
    REFERENCES clientes(id_cliente) ON DELETE CASCADE,
  CONSTRAINT fk_ventas_metodo_pago FOREIGN KEY (id_metodo_pago)
    REFERENCES cat_metodo_pago(id_metodo_pago) ON DELETE SET NULL,
  CONSTRAINT fk_ventas_navegador FOREIGN KEY (id_navegador)
    REFERENCES cat_navegador(id_navegador) ON DELETE SET NULL
);
```



```
REFERENCES cat_navegador(id_navegador) ON DELETE SET NULL
);
```

7.2 Limpieza y transformación de datos (src/etl.py)

```
def transform(df_raw):
    df = normalize_column_names(df_raw)

    # 1. Duplicados exactos
    dups = df.duplicated().sum()
    if dups > 0:
        df = df.drop_duplicates().copy()

    # 2. Fechas
    df['fecha_compra'] = parse_dates_smart(df['fecha_compra']).dt.date

    # 3. Limpieza numerica y validacion de catalogos
    for col in ['venta_total', 'monto_compra', 'tiempo']:
        df[col] = pd.to_numeric(df[col], errors='coerce')
    df.loc[~df['id_genero'].isin([0, 1]), 'id_genero'] = np.nan
    df.loc[~df['id_metodo_pago'].isin([0, 1, 2]), 'id_metodo_pago'] = np.nan
    df.loc[~df['id_navegador'].isin([0, 1, 2, 3, 4]), 'id_navegador'] = np.nan

    # 4. Registros sin cliente valido se descartan
    df = df.dropna(subset=['id_cliente']).copy()

    # 5. Normalizacion en clientes (dimension) y ventas (hechos)
    df_clientes = df[COLS_CLIENTE].drop_duplicates(subset=['id_cliente'])
    df_ventas = df[COLS_VENTAS].copy()
    return df_clientes, df_ventas
```

7.3 Contrato de registro de análisis (mcp_server/contrato.py)

```
REGISTRO: dict[str, 'Analisis'] = {}

@dataclass
class Resultado:
    datos: list[dict] = field(default_factory=list)
    resumen: str = ''
    figura: Any | None = None

def analisis(nombre: str, descripcion: str, punto: str = ''):
    """Registra una funcion de analisis como tool del agente."""
    def wrapper(func):
        REGISTRO[nombre] = Analisis(nombre, descripcion, func, punto)
        return func
    return wrapper
```

7.4 Publicación automática de tools MCP (mcp_server/server.py)

```
mcp = FastMCP('analisis-ventas-2021')

def _publicar(a: Analisis) -> None:
    def tool(**kwargs):
        try:
            return _a.contenido_mcp(a.funcion(**kwargs))
        except Exception as exc:
            return [TextContent(type='text', text=f"Error en '{a.nombre}': {exc}")]
    tool.__doc__ = f'{a.descripcion} (Punto {a.punto} del enunciado.)'
    mcp.tool(name=a.nombre, description=tool.__doc__)(tool)

for _a in REGISTRO.values():
    _publicar(_a)

if __name__ == '__main__':
    mcp.run(transport='stdio')
```



7.5 Agente conversacional (agente/agent.py)

```
root_agent = LlmAgent(  
    model=os.getenv('MODELO', 'gemini-2.5-flash'),  
    name='analista_ventas',  
    instruction=(  
        'Eres un analista de datos que responde sobre las ventas de 2021. '  
        'Responde SIEMPRE consultando las herramientas disponibles; '  
        'nunca inventes cifras ni las estimes de memoria.'  
    ),  
    tools=[McpToolset(connection_params=StdioConnectionParams(  
        server_params=StdioServerParameters(  
            command=sys.executable,  
            args=['-m', 'Practical.mcp_server.server'],  
            cwd=str(RAIZ),  
        ), timeout=60.0,  
    )],  
    after_tool_callback=guardar_graficas,  
)
```

8. REPOSITORIO

https://github.com/Aragon1342/SOG2-2S26_grupo4.git